

深度学习大作业：A 股趋势预测与模拟交易——讨论报告

本文档基于《深度学习基础大作业》PDF 全文、data/README.md 及对 data/ 目录下样例文件的核对撰写；并结合金融统计、数学建模与深度学习文献与业界实践做调研归纳。

数据抽样核对：basic.csv 约 5500+ 只股票；daily/、metric/、moneyflow/ 为按交易日截面 CSV；news/ 为东方财富快讯（按日历日聚合），stock_st/ 为 ST 名单；指数数据见 README。

一、作业要求解读（对照 PDF）

1.1 核心任务

- 预测对象：**利用过去一段时间的特征序列，预测股票未来短期收益方向（可具体化为未来 n 个交易日收益率或其符号）。
- 流程闭环：**数据处理与特征构造 → 必须包含神经网络的模型设计与训练 → 策略评估与历史回测 → 同花顺模拟交易（FDL2026） → 实验报告与反思。
- 股票池（比赛正式范围）：**除 ST 股、北交所 外的全部 A 股；训练阶段若算力或工程难度受限，可先子集（如沪深 300），但最终与比赛一致时建议对齐正式股票池（约 5000 只量级，README 与 basic.csv 一致）。

1.2 数据与时间约束（与 README 对齐）

数据类型	路径/文件	时间注意点
日频量价	daily/YYYYMMDD.csv	2016 起；按日截面，需自行 merge 成个股时序
基本面/估值/换手等	metric/	与量价同日对齐
资金流向	moneyflow/	与量价同日对齐
新闻快讯	news/	仅 2019 年起；文本字段 datetime, content, title
ST 标记	stock_st/	2016-08 起
交易日历	trade_cal.csv	用于对齐、shift 标签、停牌/休市
指数	market/、index_weight/	作基准与可选成分池

禁止未来信息：特征与标准化只能用到决策日 t 及以前可获得的信息；标签应对齐为「在 t 收盘后可计算、在 $t + 1$ 开盘前可下单」的收益率（见第五节）。

1.3 推荐策略骨架（可扩展）

1. 首日等权买入 n 只股票；之后每日卖出持仓中**预测得分最低**的 k 只，同时买入全市场中**得分最高**的 k 只 ($n \in [5, 30], k \in [1, 5]$)。
2. 比赛强调：**每日尽可能满仓**；A 股 **T+1**（当日买入次日方可卖）。

1.4 评价与回测（作业硬性/软性要求）

- **硬性**：训练/验证损失、**IC**、**ICIR**；报告规范、无泄露、可复现。
- **推荐（影响评分）**：历史回测——年化收益、夏普、最大回撤；与上证指数/沪深 300 等对比；有余力可加手续费、滑点、涨跌停、停牌、最小交易单位等约束。

二、数据字段与作业相关概念的经济学含义与使用注意

本章按 README 中最小字段（列）逐项说明：**经济学直觉 + 建模/因果上需注意的点**。未单列的表（如指数 market/）若字段与 daily/ 一致，则与下列 **OHLCV** 等字段同名同义，区别仅在标的为**指数组合**而非单券。

2.1 basic.csv（证券主数据，慢变化或静态）

字段	经济学含义	注意点
ts_code	证券在数据集中的唯一标识（交易所后缀 .SH / .SZ / .BJ 区分上市地）。	与 daily / metric / moneyflow 等表的 join 键； 北交所 .BJ 在正式比赛股票池外， 训练与回测需与作业一致过滤。
symbol	交易所内简短数字代码，便于人工识别。	与 ts_code 信息冗余； 文本匹配新闻时可能与简称并用， 注意 前导零 与跨所重复口径。
name	证券简称，承载品牌与 ST 标记（如 *ST）等市场共识信息。	更名、重组会变；NLP 链指新闻依赖简称时需 维护别名表 或模糊匹配。
area	公司注册或总部所在地域， 可作 区域经济周期 、 地方政策与产业集群 的代理。	与主营业务地未必一致；类别高基数时需编码/ 嵌入，警惕与行业 多重共线性 。
industry	行业分类，刻画 共同现金流因子与监管周期 （如周期、消费、科技）。	行业标签可能随数据源调整； 用于 行业中性化 时注意 point-in-time （历史上行业是否被重新划分）。
cnsPELL	中文拼音缩写，检索与展示辅助。	对预测一般信息增量有限；可作弱特征或不用。
market	板块/市场层级（主板、创业板、科创板、 北交所），决定 涨跌幅限制 、 投资者适当性 、 流动性结构 等制度差异。	与收益分布强相关；建模时要么显式作特征， 要么在股票池规则中剔除北交所；避免与 ts_code 后缀 重复约束 时泄漏未来制度变更（少见）。

字段	经济学含义	注意点
list_date	上市日期，公司进入公开市场融资的起点。	新股上市初期 量价与估值异常、历史窗口不足；需上市满 L 日再入池或单独处理；存活偏差讨论见 第八节 8.3 。
act_name	法律/披露意义上的实际控制人姓名或机构名。	反映 公司治理与股东背景 （国企/民企等）；文本高基、变更事件少，更适合规则过滤或主题标签而非强连续因子。
act_ent_type	实控人企业性质（央企、地方国企、民营等），与 预算软约束、融资约束、政策敏感度 相关。	类别不平衡；与 industry、market 联合易冗余；注意披露更新滞后。

2.2 trade_cal.csv（时间轴与交易制度日历）

字段	经济学含义	注意点
exchange	交易所（SSE 上交所、SZSE 深交所），决定 日历与部分产品规则 。	个股表用 ts_code 后缀已能判断交易所；日历表用于 对齐两所共同交易日 与节假日。
cal_date	自然日历日。	与 trade_date 对齐时， 非交易日 无截面行情；新闻文件按 cal_date 存时，需映射到 下一交易日 再与收益对齐。
is_open	当日是否为交易日（1 交易 / 0 休市）。	用于构造连续交易时间索引、shift 标签；休市日 禁止 伪造截面。
pretrade_date	上一交易日，用于链式计算「上一有效行情日」。	计算隔夜收益、缺失填充时比「日历减 1 天」更可靠；跨长假需注意。

2.3 daily/ 与 market/（日频 OHLCV；指数与个股字段名一致）

字段	经济学含义	注意点
ts_code	标的代码；market/ 中为指数代码（如 000300.SH）。	指数无 ST 问题；回测基准收益与个股 不可混表 除非明确对齐。
trade_date	该行情对应的交易日（YYYYMMDD）。	全表 join 主键之一； 标签永远是未来 trade_date 的收益，严防错位一日。
open	开盘集合竞价与连续竞价初期形成的 开盘参考价 ，反映隔夜信息与开盘流动性。	易受单笔大单影响；与收盘组合可刻画 日内模式 ；停牌日缺失。
high	当日买方力量上界、流动性供给与涨跌停约束下的 最高价 。	极值对波动率估计敏感；与 low 联用算振幅；需结合涨跌停制度解读。
low	当日卖方压力下界。	同上；操纵或闪崩日会产生极端 low。

字段	经济学含义	注意点
close	连续竞价结束时的收盘价，常作为 日收益核算基准 与 many 衍生品结算参考。	作业 PDF 默认用收盘价算收益； 复权 口径以数据源为准，pre_close 已按除权昨收。
pre_close	经除权除息调整后的 前一交易日收盘价 ，用于连续可比价格序列。	计算 pct_chg 的分母；做手动收益时 优先用 close/pre_close-1 与官方涨跌幅一致。
change	绝对涨跌额（价格单位），close 与除权昨收之差。	低价股与高价股不可比；截面建模多用收益率或 rank。
pct_chg	百分比涨跌幅，无量纲的 日收益代理 。	已考虑除权；接近涨跌停边界时分布截断；与其他表合并时检查 是否同一交易日 。
vol	成交量（手，1 手通常 100 股，以交易所规则为准）。	与股本结合才有「换手」经济含义； 停牌为 0 或缺失 ；拆股历史需与股本数据一致（本 README 未单独给拆股表，依赖数据源已反映在价量中）。
amount	成交额（README：千元），反映 资金参与度与流动性深度 。	单位与 moneyflow（万元）不同 ，融合前必须统一量纲；大单冲击日 amount 激增。
vwap	成交量加权平均价，近似「当日平均成交成本」的统计量。	close 相对 vwap 偏离可解读为尾盘相对全日均价的 情绪或操纵 ；指数同样适用。

2.4 index_weight/ （指数成分及权重）

字段	经济学含义	注意点
index_code	标的指数（如沪深 300）。	用于构建 可投资股票池 或行业/风格 benchmark；成分调整日有 权重跳跃 。
con_code	成分股 ts_code 。	与 daily 合并得到「某日是否属于指数」；做指数增强或限制池时需注意 调入调出滞后披露 。
trade_date	权重生效或快照日期（以数据源定义为准）。	严格回测应使用 当日已知成分 ；若仅用静态当前成分回测历史，会引入 前视偏差 。
weight	该成分在指数中的权重（通常和为 1 或接近 1）。	可用于 加权基准收益 或约束组合偏离；权重过小股票噪声大。

2.5 metric/ （估值、流动性与规模截面）

字段	经济学含义	注意点
ts_code	股票标识。	与 daily 按日 merge。

字段	经济学含义	注意点
trade_date	交易日。	与 metric 同日 close 应对齐 daily.close 。
close	当日收盘价（在 metric 表中重复存储）。	与 daily 冗余，merge 时避免重复列；不一致时应审计数据源。
turnover_rate	换手率（%），成交量相对流通股本的强度， 流动性与筹码交换 指标。	极端高换手可能是炒作或事件；新股、限售解禁期结构变化大。
turnover_rate_f	基于 自由流通股本 的换手率，更接近 可交易浮筹 的真实换手。	与 total 换手二选一或同时用需防共线；自由流通口径随指数公司调整变化。
volume_ratio	量比，当日成交相对近期均量的放大程度， 短期订单流异常 信号。	分母窗口定义依赖数据源；横截面比较需注意 停牌复牌 首日失真。
pe	市盈率（总市值/净利润），盈利估值倍数。	亏损为缺失 ；极端 PE 可能因微利分母小；跨行业比较估值陷阱多。
pe_ttm	滚动四季度（TTM）盈利的 PE，平滑季节性与单次非经常损益。	仍对亏损缺失；盈利质量差时 TTM 仍误导。
pb	市净率（总市值/净资产），资产锚上的估值。	轻资产行业 PB 参考意义弱；净资产可为负（重组股）导致异常。
ps	市销率，收入视角的成长估值。	高成长、未稳定盈利公司常用；低利润率行业 PS 可比性差。
ps_ttm	滚动四季度营收的市销率。	同上，略平滑收入波动。
dv_ratio	股息率（%），过去分红相对价格的 现金回报 代理。	与 价值因子 相关；高送转、一次性特别股息会扭曲。
dv_ttm	TTM 股息率。	更平滑；仍受股价波动分母影响。
total_share	总股本（万股），公司发行的股份总数上限概念。	用于换算市值、EPS； 单位万股 ，与 amount 千元等同表时注意数量级。
float_share	流通股本（万股），理论上可在二级市场交易的部分。	与限售、战略配售相关；流通比例影响操纵难易。
free_share	自由流通股本（万股），剔除长期战略持仓等后的 可交易性更强 股本。	与指数权重、换手 _f 一致；数据源定义需统一。
total_mv	总市值（万元），价格 × 总股本的经济规模。	单位万元 ；在因子中常取对数作规模因子；极端小市值流动性风险。
circ_mv	流通市值（万元），可交易部分的市值。	大资金容量约束更直接相关；与 total_mv 差异反映限售比例。

2.6 moneyflow/ （按成交金额档位的订单流分解）

README 规定档位（按单笔成交额）：**小单**为 5 万元以下；**中单** 5–20 万；**大单** 20–100 万；**特大单**不低于 100 万；统计基于**主动买卖**。

字段	经济学含义	注意点
ts_code	股票标识。	—
trade_date	交易日。	—
buy_sm_vol	小单主动买入量（手）。	「小单」多被文献解读为 散户净主动 的粗代理，实为金额档而非账户类型； 不可过度叙事化 。
buy_sm_amount	小单主动买入金额（万元）。	与 vol 联用可核对数据内部一致性； 单位万元 ，与 daily.amount （千元）区分。
sell_sm_vol	小单主动卖出量（手）。	买卖不对称反映该档位 净主动方向 。
sell_sm_amount	小单主动卖出金额（万元）。	同上。
buy_md_vol	中单主动买入量（手）。	介于机构与散户之间的 过渡订单 ，可能是分单算法或中小机构。
buy_md_amount	中单主动买入金额（万元）。	与股价水平相关：同样手数在不同股价下金额档不同。
sell_md_vol	中单主动卖出量（手）。	—
sell_md_amount	中单主动卖出金额（万元）。	—
buy_lg_vol	大单主动买入量（手）。	常视为 机构或大单 净主动流入的粗代理；事件日与大单卖出一同解读。
buy_lg_amount	大单主动买入金额（万元）。	大市值股票日常大单绝对量天然更大，需 标准化 （如对 amount 或 circ_mv）。
sell_lg_vol	大单主动卖出量（手）。	—
sell_lg_amount	大单主动卖出金额（万元）。	—
buy_elg_vol	特大单主动买入量（手）。	更接近 机构 block trade 或算法大单拆分后的尾部；低流动性股票样本稀疏。
buy_elg_amount	特大单主动买入金额（万元）。	—
sell_elg_vol	特大单主动卖出量（手）。	—
sell_elg_amount	特大单主动卖出金额（万元）。	—
net_mf_vol	全市场口径下的净流入量（手），买卖主动净额汇总。	需对照 README 精确定义（全档位合成）；与分项加总可做 一致性校验 。
net_mf_amount	净流入额（万元）。	常用于单因子排序； 与收益率的相关在截面上更稳定 若先标准化。

2.7 news/ （非结构化快讯）

字段	经济学含义	注意点
datetime	新闻发布时间戳。	因果核心 ：晚于当日收盘的新闻不应在「当日收盘决策」中无条件使用；应对齐到 下一交易日 或丢弃。与 trade_cal 联用。
content	正文，承载事件细节与语境。	重复转载、模板公告多；需去重与编码；长度差异大需截断或分层聚合。
title	标题， 常为高度压缩的事件摘要。	与正文一并编码可提升召回；标题党噪声需规则过滤。

表级注意：新闻自 2019 起；为全样本联合建模需 mask 或与仅文本子模型分段训练（见第六节整体建模）。

2.8 stock_st/ （风险警示证券清单）

字段	经济学含义	注意点
ts_code	被实施风险警示的证券代码。	正式比赛池 剔除 ；历史上 ST 状态影响涨跌幅与流动性，回测也应剔除以与策略可比。
name	带风险标识的简称。	可与 basic.name 对照跟踪更名。
trade_date	该条 ST 状态记录的日期。	ST 状态会变化 （戴帽/摘帽）；需用当日是否出现在表中判断，而非静态标签。
type	风险类型编码。	数据源枚举，需建映射表。
type_name	风险类型可读名称（如 ST、*ST 等细分）。	可用于分层分析不同风险成因；样本可能稀疏。

2.9 作业 PDF 中的市场、制度与交易术语

- **A 股**：中国大陆沪深交易所为主的人民币普通股票集合；本作业数据覆盖全体 A 股相关标的（比赛排除 ST 与北交所）。
- **ST 股**：被实施其他风险警示或退市风险警示的证券，定价与交易规则异于普通股票；**必须剔除**（亦见 2.8）。
- **北交所**：北京证券交易所上市公司，代码后缀 .BJ；作业正式池**剔除**。
- **沪深 300 / 上证综指 / 创业板指**：宽基或风格化**市场组合代理**，用于基准收益、风险因子与策略对比（数据在 market/ ）。
- **T+1**：当日买入份额**下一交易日**方可卖出；调仓逻辑必须与可卖持仓集合一致。
- **满仓**：资金尽可能全部持股；比赛公平性约束，与实务中「留现金」不同。

2.10 作业 PDF 中的收益、风险与回测评价术语

- **日频数据**：每个交易日至多一个观测；与 tick 数据相比信息集更粗但工程成本低。
- **短期收益方向**：模型输出的排序或符号对应未来 n 日（常 $n = 1$ ）收益符号或相对基准的超额方向。
- **年化收益率**：将样本期收益换算到年化尺度便于比较；**极短样本年化不稳定**，报告需说明。

- **夏普比率**：单位波动下的超额收益，**风险调整绩效**指标；无风险利率常近似为 0 或短债利率。
- **最大回撤**：峰值到后续谷底的最大跌幅，刻画**尾部损失路径**与杠杆容忍度。
- **IC（信息系数）**：预测分数与未来收益的**截面相关系数**，衡量排序能力。
- **ICIR**：IC 均值与 IC 标准差之比，衡量**预测稳定性**而非单次运气。
- **方向胜率**：预测符号与实际收益符号一致的比例（可选指标）。

2.11 作业 PDF 中的建模、统计与作业用语

- **高噪声**：条件于公开信息，收益可预测部分弱、扰动强，导致估计方差大。
- **非平稳性**：边际分布、波动率聚集与结构断点随时间变化，违反经典平稳假设。
- **复杂依赖结构**：非线性、高阶交互、长记忆与截面相关（共同因子）并存。
- **特征标准化 / 归一化**：消除量纲、利于优化；**禁止用全样本未来信息拟合 scaler**（PDF 强调）。
- **特征工程**：从原始字段构造对新任务信息更集中的输入。
- **滑动窗口样本**：用连续 L 个交易日特征张量预测其后收益标签。
- **时间截面特征**：同一交易日内跨股票的可比变换（如截面 rank、分位）。
- **时间序列技术指标**（如 **MACD**、**RSI**）：由单券历史价格/成交量算出的**技术分析统计量**；经济学上多解释为动量/均值回复/过热的代理，统计上需防数据挖掘。
- **MLP**：多层全连接网络，非线性基线。
- **Transformer**：自注意力序列模型，捕获长程依赖；金融场景需强正则与防泄露窗口设计。
- **数据泄露**：特征或标准化中无意使用决策时尚不可知的信息，导致**虚高回测**。
- **Vibe Coding**：依赖 AI 生成代码而缺少人工审阅与测试；作业要求自行验证实现。

三、数据集结构与「全数据使用」的工程含义

3.1 基础量价（daily/）

字段经济学含义见**第二节 2.3**；工程上可构造：

- **收益与波动**：对数收益、已实现波动（Parkinson/Garman-Klass 等）、振幅。
- **流动性**：成交额、换手（亦可与 metric 交叉验证）、Amihud 非流动性等。
- **微观结构代理**：收盘价相对 VWAP 的偏离等。

3.2 进阶：基本面截面（metric/）

各字段见**第二节 2.5**；适合作为**慢变量**与估值锚，缓解纯价量过拟合噪声。

3.3 进阶：资金流（moneyflow/）

各字段见**第二节 2.6**；经济学直觉：**大单净主动买入**常被视为机构行为代理；需与市值/成交额标准化后使用，避免大市值天然大单多。

3.4 进阶：新闻（news/）

字段见第二节 2.7。样例显示为**全市场快讯**（宏观、行业、个股公告混排），并非每只股票一条。要「用到全部新闻」需：

1. **按时间截断**：对决策日 t ，仅使用 $\leq t$ 且与交易决策时点一致可获得的新闻（见 2.7 datetime）。
2. **与股票关联**：规则/模型抽取实体（公司名、证券简称、ts_code 出现在文本中等）+ **语义检索**将新闻聚合到个股或行业；无法链接的可作为**市场层或行业层**因子。
3. **2016–2018 无新闻**：联合模型中应对该模态设 **mask**、**缺失指示变量**，或用仅价量子模型训练到 2018，再与 2019+ 多模态微调（见第六节整体建模）。

3.5 其它：basic.csv、stock_st/、trade_cal.csv、指数

- basic：字段见 2.1；industry、market 可作 **group 中性化**与行业 embedding。
- stock_st：见 2.8；与股票池过滤一致。
- trade_cal：见 2.2；对齐与 shift。
- market / index_weight：见 2.3、2.4；构建基准超额收益与可选成分池。

四、问题形式化与标签设计

4.1 预测目标（建议）

- **回归**：预测未来 n 日**超额对数收益**（相对市场或行业），或对收益做 **tanh / rank** 压缩以减轻极端值影响。
- **分类**：二分类「 n 日收益是否大于 0（或是否跑赢基准）」；可采用 **focal loss** 处理类别不平衡。

n 可与调仓周期、比赛持有期一致（如 1、3、5）；需与回测再平衡频率一致以避免目标与执行错配。

4.2 截面 vs 时序

- 作业本质是**大横截面 + 短面板**：每日 4000–5000 只股票，各自 L 日历史窗口。
- 评价上业界常用 **截面 IC**（同日全股票预测值与未来收益的 Spearman/Pearson 相关），与 PDF 要求一致。

五、预处理与特征工程（强调无泄露）

本节放在**建模（第六节）与回测（第八节）**之前，原因是大截面股票机器学习里，收益差异的很大一部分来自「管线是否干净」而非网络结构；业界与顶刊文献反复强调：**前视偏差、错误的标准化、错误的交叉验证、以及多重检验下的数据窥探**，会把夏普与 IC 抬到「论文里很好看、实盘不可用」的水平。

5.0 文献与业界框架：为何「预处理」本身值得对标顶刊写法

1. Gu, Kelly & Xiu (2020) *Review of Financial Studies*（下称 **GKX**）在「机器学习资产定价」设定下系统比较了线性模型、树与神经网络等，发现**树与神经网络**常占优，且重要信号与**动量、波动、流动性**等经济机制一致。该文

配套工程与复现博客（如 Tidy Finance 对 GKX 的复现说明）指出：对大量公司特征，常见做法是**逐期（period-by-period）做截面秩变换**，再把秩线性映射到 $[-1, 1]$ ，使每个交易日上各预测变量具有可比尺度，并显式处理缺失秩（NA 不参与排序边界）。这与「在全样本上 fit 一次 StandardScaler」在**信息经济学含义上完全不同**：后者在数学上等价于使用了未来各期的联合分布信息，属于作业 PDF 明确禁止的泄露源之一。

- 论文信息： *Empirical Asset Pricing via Machine Learning*, RFS 2020；NBER 工作论文版本：

<https://www.nber.org/papers/w25398>

- 复现中对秩变换的逐步说明（英文）：<https://www.tidy-finance.org/blog/gu-kelly-xiu-replication/>

2. Giglio, Liao & Xiu (2021) *Review of Financial Studies* 《Thousands of Alpha Tests》讨论资产定价中**海量检验与数据窥探（data snooping）**：当研究者对大量因子/策略做筛选时，「看起来显著」的比例会系统性偏高。其框架给出在大检验数下仍渐近有效的推断思路（含 wild bootstrap 等有限样本改进）。对本作业的启示是：**特征工程与模型搜索空间越大，越要在验证协议与报告里交代「试过多少设定、最终规则是否由单次 holdout 决定」**，避免把网格搜索等价成「无成本的信息」。

- 常用入口：SSRN https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3259268

3. Feng, Giglio & Xiu (2020) *Journal of Finance* 《Taming the Factor Zoo: A Test of New Factors》从**因子动物园**角度讨论大量候选因子/预测变量下的检验与冗余问题，与「高维特征 + 机器学习」场景直接相关：预处理阶段若不**做经济含义约束、共线性处理、或 shrinkage**，模型容易拟合到「样本内可解释、样本外漂移」的虚假交互。

- <https://doi.org/10.1111/jofi.12927>

4. Kozak, Nagel & Santosh (2020) *Journal of Financial Economics* 《Shrinking the Cross-Section》强调在横截面预期收益估计中使用**收缩（shrinkage）/贝叶斯先验**以降低估计误差与噪声交易；工程上对应：**对极端预测做收缩、对因子暴露做先验约束、或在组合层做风险模型收缩**。这与「winsorize 预测值 / 对权重加 caps」是同一类思想在不同层的体现。

- <https://doi.org/10.1016/j.jfineco.2019.07.008>

5. Mekelburg & Strauss (2024) *Journal of Empirical Finance* 《Pooling and winsorizing machine learning forecasts to predict stock returns with high-dimensional data》（DOI: 10.1016/j.jempfin.2024.101538）发现：单一 ML 模型预测误差可能很大并导致「预测失败」，但对多模型预测做**winsorize 后再 pooling（集成）**，在多国市场样本上可获得更一致的样本外可预测性；并讨论稀疏/稠密结构随时间演化。对本作业启示：**集成 + 对预测尾部的稳健处理**不是「技巧」，而是近年实证金融里被系统验证过的稳定增益来源之一。

- RePEc/IDEAS 摘要页：<https://ideas.repec.org/a/eee/empfin/v79y2024ics0927539824000732.html>

6. López de Prado (2018) 《Advances in Financial Machine Learning》（业界量化经典教材）系统提出 **Purged K-Fold / Combinatorial Purged Cross-Validation (CPCV)** 等：当标签是未来 h 日收益时，训练集与验证集样本在时间上**重叠的标签窗口**会泄漏信息，需要在折间 **purge（清除）** 并用 **embargo（禁运期）** 隔断相邻折。深度学习若仍用「随机打乱 mini-batch 当作 i.i.d.」而不处理面板结构，会低估方差、抬高泛化错觉。

7. 关于「**泄露如何量化**」的警示性研究：近年有工作以仿真/实证方式展示**滚动归一化窗口若向前污染数日、或误用 K 折交叉验证**时，夏普等绩效指标可被大幅抬高；这类结论用于强化「必须用时间顺序验证」的纪律（具体作者与版本以你最终引用文献库为准，可在 Research Square / SSRN 以 *financial machine learning data leakage* 检索核对）。

8. **Kakushadze (2016) arXiv:1601.00991 《101 Formulaic Alphas》**代表业界因子工厂文化：用有限算子库在 OHLCV 上生成大量候选信号；其启示是「**先构造经济含义清晰、可复现的算子特征**，再交给神经网络做非线性组合」，往往比直接把原始五价直接塞入网络更稳、更易写报告。

下文按「作业 PDF 要求链条」展开：**信息集 → 样本与标签 → 时间切分/验证 → 缺失与表连接 → 极值与稳健缩放 → 截面标准化/中性化 → 特征构造 → 文本 → 窥探控制 → 自查清单**。

5.1 信息集、决策时点与「可交易标签」对齐（最优先、最细）

- **信息集定义**：在交易日 t 的收盘决策问题中，所有特征只能依赖「在 t 日收盘前（或数据供应商定义的盘后固定时点前）理论上可获得」的信息。你们数据为日频盘后更新场景时，应对齐为：用 $\leq t$ 的 `daily/metric/moneyflow` 与按规则截断后的新闻，预测 **从 t 收盘到未来可交易实现** 的收益（常见为 $t + 1$ 收盘相对 t 收盘，或 $t + 1 : t + n$ 复利收益）。
- **严禁混用「日历日」与「交易日」**：`news/` 按自然日文件存储时，若新闻时间晚于交易所收盘，应映射到 **下一交易日** 再进入该日的特征，否则属于「用到了当时尚未进入投资者信息集」的灰区泄露。
- **复权与收益率**：优先使用 `pct_chg` 或 `close/pre_close-1` 与数据源一致；跨表构造的收益率必须保证 **同一 `trade_date` 语义**（合并键加断言）。
- **重叠标签（overlapping labels）**：若 $n > 1$ ，相邻训练样本的未来收益窗口在时间上重叠，标准 K 折会让验证折「看到」与训练折共享的未来段；应按 López de Prado 思路在折间删除重叠区间或使用 `purged CV`。
- **对齐比赛 T+1**：标签定义与「哪一天允许卖出」共同决定可执行收益；预处理阶段就要把「预测 horizon」与「调仓频率」写入同一张设计表，避免模型学 $n = 5$ 但策略每天换仓的错配。

5.2 时间切分、训练/验证/测试协议：walk-forward、purge、embargo

- **禁止**：把全时段样本随机打乱后做 K 折；把「全历史 mean/std」用于标准化；在验证集上反复调参后仍声称验证集是「样本外」。
- **推荐基线：滚动或扩展窗口（walk-forward）**：用 $[0, T_{\text{train}}]$ 训练，在 $(T_{\text{train}}, T_{\text{train}} + H]$ 验证；时间向前滚动。验证集只做**一次或少次**模型族选择；最终测试用比赛期或保留的最后一段。
- **进阶**：对树模型与神经网络，使用 **Purged + Embargo** 的交叉验证折，使相邻折之间不仅「训练在前、验证在后」，还剔除标签窗口重叠与边界泄漏（AFML 第 7 章框架）。
- **多模态时间不对齐**：新闻自 2019 起，建议构造 **缺失指示变量** 或分段训练（先 2016–2018 纯数值预训练，再 2019+ 联合微调），并在报告中报告 **两段样本的指标对比**，避免读者误以为全期都有文本。
- **与 GKX 的 out-of-sample 叙事一致**：顶刊资产定价论文通常强调「训练窗滚动 + 严格 OOS」，这不是形式主义，而是控制 **regime shift（结构突变）** 下模型自由度过高的问题；Rossi (2021) *Journal of Economic Literature* 对预测不稳定性的综述也可作为「为何时间切分比调参更重要」的理论支撑。

5.3 样本构造：股票池、ST/北交所、停牌、新股与「可交易集合」

- **股票池**：与比赛一致时，应在特征层就剔除 **ST**（`stock_st/` 当日命中）与 **北交所**（`ts_code` 后缀 `.BJ` 或 `basic.market`）。若研究子池（沪深 300），必须用 `index_weight/` 的 **point-in-time 成分** 过滤，避免「用 2025 成分回测 2018」。
- **停牌与零成交**：停牌日常表现为 `vol=0` 或缺失；应用 `trade_cal` 确认是否交易日。对停牌日：要么剔除该股票该日样本，要么用 **mask** 让网络显式学习缺失模式；**不要用未来复牌后的价格向前填充**当作当日特征。
- **新股与短历史**：上市不足 L 窗长的股票要么不入训练，要么用 **较短窗口 + 填充掩码**；否则尾部小票会带来「伪序列」与幸存者偏差讨论（见第八节 8.3）。
- **横截面规模不平衡**：每日可交易股票数波动；若某日有效样本极少，截面秩/标准化方差不稳定，可设最小截面样本阈值（如少于 200 只则跳过该日或只用全局缩放）。

5.4 缺失值处理：从「填数」到「可识别的缺失机制」

- **价格/成交额缺失**：区分「真缺失」与「停牌」；二者经济机制不同。深度学习可用 **可学习缺失指示**（missing indicator channel）或 **NaN-aware** 归一化（先秩变换再对缺失单独编码）。

- **PE 等估值缺失**：亏损公司常见；**不要用全截面均值填充**掩盖经济状态。推荐：**缺失指示 + 条件填充**（行业内中位数）或 **两阶段模型**（先预测是否盈利再预测收益）。GKX 式秩变换对 NA 的处理要点是：缺失不参与秩的极值归一，避免把「缺失」错误变成「最大/最小」。
- **资金流与量纲**：moneyflow 金额单位为**万元**，daily.amount 为**千元**；合并前必须统一，否则网络学到的是「单位 artefact」而非经济信息。
- **新闻缺失**：无新闻日不等同于「零情感」，而应等价于 **文本模态缺失**，由门控网络降权（见第六节）。

5.5 极值与重尾：截面 winsorize、稳健目标与「预测 winsorize」

- **截面 winsorize（推荐默认）**：对每个 trade_date、每个特征，在截面上将分位数以外（如 0.5%–99.5% 或 1%–99%）截断。目的不是「造假」，而是降低**微盘股、数据错误、极端事件**对梯度与相关估计的支配；与 Mekelburg & Strauss (2024) 对 **预测值 winsorize** 的思想一致：金融收益重尾下，极端预测往往是噪声放大器。
- **时间序列 winsorize（谨慎）**：仅在**因果滚动窗**内对单只股票历史做截断，避免用未来分位点。
- **标签处理**：可对超额收益做 **tanh 压缩**或分位数映射，减轻 MSE 被极端日主导；分类任务可用 **focal loss** 处理涨跌不平衡。
- **对数化**：对 total_mv、amount、成交额类右偏变量常用 $\log(1 + x)$ ，但注意 zeros 与缺失的定义顺序（先处理缺失与停牌，再 log）。

5.6 标准化与截面可比：GKX 式秩映射、z-score、分位数与「绝不用全样本 scaler」

- **GKX / Tidy Finance 复现中强调的秩映射（经典做法）**：在每个交易日 t ，对同一特征在截面上排序，将秩线性变换到 $[-1, 1]$ ，使「当天最大」映射到上界、「当天最小」映射到下界；**逐期重复**。其优点：
 - 对单调变换稳健，适合后面接树或神经网络；
 - 与 **IC / 排序选股** 目标一致（预测的是相对排序而非绝对价格尺度）；
 - 对重尾分布比 z-score 更不易被单日极端值绑架。
- **截面 z-score（替代或补充）**：在 winsorize 后，按日减截面均值除以截面标准差；若当日截面方差极小，需加 **数值下限** 或对标准差做收缩（与 Kozak et al. 的 shrinkage 思想一致）。
- **滚动训练窗 z-score（用于部分时序模块）**：仅用 $[t - W, t]$ 内已实现的收益/波动统计量估计均值方差，再标准化当前输入；**W 的右端点不得跨过决策日之后**。
- **明确禁止**：sklearn.preprocessing.StandardScaler().fit(全时段) 后 transform 各年；或 BatchNorm 在「全历史」上估计 running statistics 后声称无泄露——这在严格因果意义下不成立。若使用 BatchNorm，更合理的是在**每个训练折内**重新估计，或在网络中用 **LayerNorm / GroupNorm** 降低对全局统计依赖。
- **行业/规模中性化的前置**：中性化常在秩/z-score 之后或对原始经济变量做回归残差；实现上可用「行业内秩」两步法近似，降低计算量。

5.7 行业、规模与风险因子中性化（Barra / Fama-MacBeth 思想的工程化）

- **行业中性化**：对行业虚拟变量或行业固定效应做回归，取残差作为因子输入；或对每个特征做「减行业当日均值」。目的：减少预测分数只是「押注某一行业 beta」的概率。
- **规模（log市值）中性化**：小市值溢价会使模型「永远偏小票」；常用 WLS 回归（权重与市值或波动相关）或直接在损失里加 **规模暴露惩罚**。
- **市场 beta 中性（可选）**：用滚动 60 日或 120 日对市场收益回归得 β ，将收益或特征对 β 正交化；实现复杂但报告加分。

- 与 Feng et al. (2020) 一致的态度：中性化不是「去掉 alpha」，而是把可交易的 alpha 与已知风险补偿来源分离，使验证集上的 IC 更接近「可复现的异质性信息」。

5.8 特征构造：价量算子、Alpha 工厂与「文献锚定的信号族」

- **价量算子层**：收益率（1/5/10/20 日）、波动（Parkinson/日内振幅）、成交量突增、Amihud 非流动性、价格相对 VWAP 偏离、最高最低相对收盘的位置等。
- **WorldQuant 101 风格**：用 tsrank、tsdelay、tsdelta、tscorr 等算子在面板内构造大量候选，再做截面 rank；适合作为 CNN/Transformer 前的显式因子层 或作为 树模型特征。
- **GKX 文结论导向**：在解释变量重要性时，优先检查是否主要落在 **动量、波动、流动性** 族；若重要性集中在「难以解释的高频交互」，要怀疑过拟合或泄露。
- **资金流特征**：在统一量纲后，构造「大单净流入 / 成交额」「特大单买卖不对称」等比率特征，再做截面秩；避免 raw volume 级别特征被大市值支配。
- **指数共同因子**：从 market/ 构造市场波动率（如 HS300 20 日实现波动）、趋势状态，作为**全局 conditioning 变量** 输入网络或作为中性化回归里的控制变量。

5.9 文本模态预处理（与数值管线同样严肃）

- **清洗**：HTML 标签、重复空格、全角半角统一；繁简转换；去除明显无关模板段。
- **去重**：同一公告多源转载可用 SimHash/MinHash + 时间窗；避免同一信息被计数三次导致情感「虚假放大」。
- **时间因果**：见 5.1；与 trade_cal 合并做 **event time** → **trade_date** 映射。
- **表征**：中文金融可尝试 **FinBERT / 领域继续预训练**；长文本用分段 + attention pooling；可辅以 **事件类型多任务**（监管处罚、盈利预告、订单合同等）提升表征鲁棒性（相关实证见 arXiv 上 FinBERT-LSTM 等预印本，终稿请按学校规范核对引用）。
- **与数值融合前**：建议文本分支单独输出 **低维 embedding**，再与数值拼接；并对无新闻样本保留 **mask**，避免把「无文本」学成「极端利空」。

5.10 数据窥探、多重检验与「报告纪律」（与 Giglio–Liao–Xiu 框架对齐）

- **因子/特征搜索**：若尝试了上百个交互特征，最终只报告最好的一个，本质上属于多重检验；应在附录列出 **搜索空间规模** 或使用更保守的阈值解释。
- Giglio, Liao & Xiu (2021) 给出的方向性启示：把「检验数很大」纳入推断框架；本作业虽非正式学术发表，但评分上**诚实披露调参路径**通常优于「只给最优结果」。
- **基准模型**：至少保留 **简单 MLP / 线性回归 + 行业固定效应** 作为对照，证明增益不是来自某段偶然区间（与 GKX 对照精神一致）。
- **稳定性诊断**：除 IC 均值外，必须跟踪 **IC 时间序列**与分市场阶段（牛/熊/震荡）表现；Rossi (2021) 强调预测模型在结构突变下会失效，报告中讨论这一点是加分项。

5.11 与本作业 PDF 条款逐项对照（提交前自查）

PDF / 数据要求	预处理层对应动作
禁止随机打乱时间	mini-batch 内可按日分组；评估用时间 walk-forward。
禁止全样本标准化	采用逐日截面秩/截面 z-score 或滚动窗估计 scaler。

PDF / 数据要求	预处理层对应动作
禁止未来信息	新闻时间戳映射；指数成分 point-in-time；标签 shift 正确。
缺失与异常	winsorize + 缺失指示；停牌/新股规则写清。
进阶数据单位	amount 千元 vs moneyflow 万元统一。
可复现	随机种子、版本号、requirements.txt、特征列表冻结。

5.12 初学者导读：这些论文/做法在说什么，以及你们实验里「一步步该怎么做」

下面用**尽量少公式**的方式，把第五节里出现的文献与业界习惯，翻译成「时间序列 + 深度学习 + 特征工程」初学者能跟上的语言，并**逐项对应到你们 A 股大作业的数据与代码任务**。

(1) 先建立一个心智模型：你们做的不是「单只股票 K 线预测」

- **普通时间序列**课常讲：一条序列 $x_1, x_2, \dots$ ，预测下一步 x_{t+1} 。
- **你们的数据是**：每个交易日 t ，横截面上有 **几千只股票**；每只股票又有一段 **过去 L 天** 的历史。这叫**面板数据 (panel)**：「时间 × 股票」二维网格。
- **业界与 GKX 类论文的预测对象**往往是：在 t 时刻，用所有股票的可得特征，去解释或预测 **下一期（或未来几期）收益的横截面关系**；评价常用 **IC**（排序相关），而不是单序列 MSE。

你们实验里：写代码时脑子里要有一张表：行 = trade_date，列 = ts_code，格子里是特征或标签；模型每天对「当日所有股票」吐一个分数向量。

(2) GKX (2020)：机器学习在「很多公司特征」上能不能定价？

- **他们的问题**：给定几十到上百个公司层面的预测变量（类似你们的 metric + 价量衍生特征），能不能用非线性模型更好地预测未来收益或风险溢价？
- **他们的核心做法（与你们最相关的是预处理）**：对特征做**逐日截面处理**——每个交易日各自排序、映射到可比区间（复现博客里常写成映射到 $[-1,1]$ ），让神经网络/树「每天吃到的输入尺度一致」，且**不依赖全样本的全局均值方差**。
- **为什么重要**：股价、成交额、市值的量纲差几个数量级；神经网络对尺度敏感。若用「全期 fit 的 StandardScaler」，等于偷偷告诉模型「未来分布长什么样」，作业里算**泄露**。
- **他们论文结论（你们要会复述）**：树与神经网络往往强，重要信号常落在**动量、波动、流动性**附近——这给你们写「经济含义」段落时可以直接对照自己的特征重要性图。

你们实验里怎么做（可写进报告「实现步骤」）：

1. 从 daily/ merge 出每只股票每日行情；按作业过滤 ST、北交所。
2. 构造一批特征列（收益率滞后、波动、换手、资金流比率等，见 5.7–5.8）。
3. **对每个 trade_date，在当日所有股票截面上**，对每个特征做 winsorize（可选）→ **秩变换到 $[-1,1]$** （或先做截面 z-score）；PE 等缺失用「不参与排序边界」的规则处理。
4. 标签例如：fwd_ret = close[t+1]/close[t]-1 或相对沪深 300 的超额收益；**保证特征只用 $\leq t$ 的信息**。
5. 训练一个 **MLP 或 LSTM** 作为「GKX 精神下的基线」，再与更复杂模型对比——这是论文里常用的「对照」。

(3) Giglio–Liao–Xiu (2021): 不是模型不好, 是「试太多次」会假阳性

- **直觉**: 如果你抛硬币 1000 次, 总会有一段「看起来很像有规律」; 因子挖掘也一样, 试 500 个特征组合, 最好的那个可能只是运气。
- **论文贡献 (你们不用会推导)**: 在「检验次数巨大」时, 如何控制**错误发现 (false discovery)**, 让「显著」更可信。

你们实验里怎么做:

1. 在报告里诚实写: 尝试过哪些特征子集、哪些窗口 L 、哪些模型; **最终提交的配置**是依据哪一段**验证期**选的。
2. 不要把「在整段历史上网格搜索到最优」再拿同一段历史当「样本外」吹嘘; 至少保留 **最后一年/一季完全没参与选参**的曲线或指标。
3. 若课程允许, 可附录一张「调参次数 vs 性能」说明, 体现你们理解 **Giglio–Liao–Xiu (2021)** 对多重检验的担忧。

(4) Feng–Giglio–Xiu (2020) 「因子动物园」: 特征太多时, 很多是重复的

- **直觉**: 一百个因子可能只有十个独立方向, 其余是线性组合或噪声。
- **对深度学习的含义**: 网络容量大时, 会把噪声拟合成「看起来很酷的交互」。

你们实验里怎么做:

1. 特征不要盲堆: 先分族 (动量/波动/流动性/估值/资金流/文本), 每族保留若干代表。
2. 训练后看 **相关性矩阵 / VIF / 简单 PCA 方差贡献** (写报告即可, 不必上复杂检验), 解释你有没有去掉明显共线的列。
3. 与 **简单模型 (少特征 MLP)** 对比, 证明复杂模型不是纯过拟合。

(5) Kozak–Nagel–Santosh (2020) 收缩: 预测太「极端」往往是噪声

- **直觉**: 横截面上估计「谁明天涨最多」误差很大; 把预测往 0 或往市场均值**拉一点**, 组合反而更稳。
- **论文是理论+资产定价**, 你们工程上对应: **对模型输出做 winsorize**、或 **对权重加 cap**、或 **训练目标加 L2**。

你们实验里怎么做: 在得到每日每只股票的 `raw_score` 后, 在截面上对分数做 1%/99% 截断, 再送入调仓函数; 对比截断前后 IC/IR 与回测夏普 (与 Mekelburg & Strauss 2024 的「预测层 winsorize + 集成」叙事一致)。

(6) Mekelburg & Strauss (2024): 单模型会「崩」, 集成 + 稳健化更像业界

- **他们发现了什么**: 很多 ML 模型单独预测收益会阶段性完全失效; 把多个模型的预测 **pooling**, 并对极端预测 **winsorize**, 样本外更稳。
- **初学者理解**: 就像「多个弱学习器投票」比「押宝一个天才模型」更不容易翻车。

你们实验里怎么做: 训练 2–3 个差异大的模型 (例如 LSTM + 轻量 MLP + 只用基本面的 MLP), 验证集上估计权重, 做加权平均或秩平均得到最终 `score` (与第六节「联合打分」衔接)。

(7) López de Prado (AFML): 标签是未来几天收益时, 交叉验证不能乱折

- **直觉**: 若标签是「未来 5 日累计收益」, 相邻两天的训练样本标签窗口**重叠了 4 天**, 随机 K 折会让训练集「偷看」验证集标签里共享的未来信息。
- **做法名字记住即可**: **Purged CV** (折间删掉重叠区间)、**Embargo** (验证折后再空一段训练不用)。

你们实验里怎么做：若 $n > 1$ 日标签，报告里说明验证方案是 **简单时间切分** 还是 **purged**；初学者至少做到：**绝不对**（股票，日期）样本做随机 K 折。短期 $n = 1$ 也要养成习惯，写清「训练窗结束日 < 验证窗起始日」。

(8) 101 Alphas：业界「因子工厂」——用算子批量生产候选信号

- **直觉**：不是手工想 3 个特征，而是用 `delay`、`delta`、`rank`、`corr` 等小积木在 OHLCV 上**程序化**拼出很多候选，再筛选。
- **对深度学习的分工**：Alpha 负责提供「**经济含义清晰、可复现**」的输入；网络负责学**非线性组合**。

你们实验里怎么做：先实现 10–30 个算子特征（动量、反转、振幅、量比变化），跑通 IC；再把这些列喂给 LSTM/Transformer，比直接 raw OHLC 更容易写报告、也更容易 debug。

(9) 业界「Barra / 风险模型」口吻：行业、市值中性不是玄学

- **直觉**：你发现模型总是买「某一行业」或「小市值」，可能不是 alpha，而是**风险暴露**（行业 beta、小盘溢价）。中性化 = 先把这些已知方向从特征或预测里**扣掉**，再看还剩什么。

你们实验里怎么做：对每个交易日，每个特征减 **行业均值**（`basic.industry`），或对预测分数做「对行业虚拟变量回归取残差」；市值用 `log(total_mv)` 同理。报告里放一张「中性化前后行业暴露」对比图会很好看。

(10) 小结：你们第五节「最小可交付」清单

1. 统一 `trade_date` 与 `ts_code` 主键；单位换算（千元/万元）。
2. 逐日截面 `winsorize` + 秩或 z-score；**禁止**全样本 `StandardScaler`。
3. 标签 `shift(-1)` 或显式 `t+1` 收益；新闻时间对齐。
4. 时间切分训练/验证；可选多模型集成 + 预测 `winsorize`。
5. 报告写清：对照模型、搜索空间、是否中性化——对应 **Giglio-Liao-Xiu (2021)** 与 **Feng-Giglio-Xiu (2020)** 所强调的「透明搜索空间 + 审慎推断」态度。

六、整体建模方案：分模态建模 + 联合打分（集成）

以下方案满足：**神经网络必选、尽量用尽价量/基本面/资金流/新闻/指数**，且可解释「为何分模态」。输入侧默认已按第五节完成对齐、清洗、标准化与防泄露处理；若跳过该节，回测与 IC 往往不可复现或虚高。

6.1 模态 A——价量 + 资金流时序（深度时序主干）

- **输入**：每只股票过去 L 日的多变量序列（OHLCV、金额、VWAP 衍生、资金流拆分、可与 `metric` 中换手/量比等合并）。
- **模型候选**：
 - **LSTM/GRU**：基线强、训练稳。
 - **Temporal Fusion Transformer (TFT)** (Lim et al., *International Journal of Forecasting*, 2021; arXiv:1912.09363)：显式处理**静态协变量**（行业、市值分组、上市年限）+ 多尺度时序依赖，并提供变量重要性解释，适合写进报告「架构思考」。
 - **Transformer / Informer 类**：注意正则化与小样本过拟合；可配合 **PatchTST** 等降采样思路（若引用需单独文献支撑）。

- **输出：**每只股票标量得分 $s_{i,t}^A$ 或未来收益分布参数。

原理：短周期价格服从近似鞅但有**风险溢价与行为金融驱动的可预测成分**；深度网络擅长捕捉**高维非线性交互**（Gu, Kelly & Xiu, 2020，见**第八节**文献对照）。

6.2 模态 B——当日/短期基本面截面（深度交叉截面网络）

- **输入：**metric 中估值、市值、换手、量比等；可拼接滚动统计（如 PE 的 20 日分位数变化，仍仅用过去信息）。
- **模型：**FT-Transformer / TabTransformer、或浅层 MLP with dropout（Gu et al. 发现树与神经网络在资产定价特征上表现突出）。
- **输出：** $s_{i,t}^B$ 。

原理：估值与成交活跃度反映**贴现率与流动性补偿**；截面网络学习「在同一日内相对定价错误」。

6.3 模态 C——新闻文本（语义分支）

- **预处理：**分句、去重、繁简统一；可选金融领域预训练 FinBERT / FinRoBERTa 类模型抽取句向量或情感极性。
- **聚合：**对股票 i 在 $(t - L_{\text{news}}, t]$ 内所有相关新闻做 **attention pooling** 或 **hierarchical attention**（日→条）。
- **输出：** $s_{i,t}^C$ ；若无相关新闻则输出 **learned prior** 或置零并由门控降权。

文献线索：金融情感与收益可预测性有大量工作，如基于 BERT 构建情感指数再结合 LSTM 的方向（例：arXiv:1906.09024）；近期亦有 FinBERT 与贝叶斯特征选择、FinBERT-LSTM 等组合框架（如 arXiv:2403.04427、arXiv:2407.16150 等，需在正式报告中按学校引用规范列出）。

6.4 模态 D——市场层（指数与宏观情绪）

- 使用 market/ 中上证、沪深 300、创业板指构建**市场状态变量**（波动、趋势、广度代理若可从个股聚合）。
- 作为 TFT 的**已知未来输入需谨慎**：通常仅将指数历史作为**共同因子通道**，或作为**门控**（regime-switching）：高波动期降低杠杆或降低换手 k 。

6.5 联合打分（融合）

推荐可学习融合 + 稳健性融合两层：

1. 门控网络（Gating）：

$s_{i,t} = \sigma(w_A z_{i,t}^A + w_B z_{i,t}^B + w_C z_{i,t}^C)$ ，其中 z 为各分支 logits 或嵌入， w 可依赖市场波动（由指数序列经小型 RNN 产生）。对无新闻样本令 $w_C \approx 0$ 。

2. 秩融合（Rank ensemble）：各分支在验证集上按 IC 或 ICIR 加权：

$s_{i,t} = \sum_m \alpha_m \text{rank}(s_{i,t}^m)$ ， α_m 由时间滚动验证估计（仍避免用未来全样本调参）。

原理：不同模态噪声结构不同；**模型平均**在统计学习理论中可降低方差；秩融合对 heavy-tail 收益更稳健。

6.6 初学者导读：GKX / TFT / 多模态文献怎么读，以及你们「模型部分」最小实现路径

(1) GKX (2020) 与第六节的关系：第六节是「在干净特征上选网络结构」

第五节讲的是「把输入变成神经网络吃得下、且不泄露的样子」。GKX 原文比较了多种机器学习模型在同一套规范处理后的特征上的表现——这提示你们：先把 MLP 跑通 + IC 为正，再换复杂结构，否则调参全在拟合噪声。

你们实验里：

- **基线 1**：当日截面特征 → MLP (或 FT-Transformer 若你们熟悉表格深度学习) → 预测 `fwd_ret` 或排序分数。
- **基线 2**：过去 L 日序列 → LSTM/GRU → 分数。
- **对照结论写法**：若复杂模型相对 MLP 提升很小，要在报告里讨论「是否值得增加过拟合风险」——这是审稿人与助教爱看的反思。

(2) LSTM/GRU：你们在学什么「时间结构」？

- **直觉**：LSTM 记住的是「过去若干天里哪些模式与接下来收益相关」，例如连续放量、波动抬升、短期反转等。它不是魔法，输入差则输出差。
- **与经典时间序列 AR 模型的关系**：AR 是线性记忆；RNN 类是非线性记忆。

你们实验里：把每只股票整理成形状 $[L, F]$ 的张量 (L 天、 F 个特征/天)，标签是 t 日决策对未来收益的标量；训练时用按日期 batch 或混合 batch，但验证与测试严格按时间走。

(3) TFT (Lim et al., 2021, IJF)：适合写进报告的「结构化时序模型」

- **论文在解决什么**：很多序列模型要么只管过去序列，要么不好加入「股票不变的信息」(行业、市值分组)。TFT 把输入分成静态协变量 (每只股票不随日变的标签)、过去已知的时变输入、以及可选的「未来已知的日历特征」等，并用门控 + 注意力自动选特征。
- **初学者抓住两点**：① 能喂 `industry` 这类静态信息；② 能输出变量重要性 (写报告比纯 LSTM 友好)。

你们实验里：

- **静态变量**：`basic` 里的 `industry` (one-hot 或 embedding)、`market`、上市年限等 (由 `list_date` 与 `trade_date` 算天数，注意只用过去)。
- **时变变量**：第五节处理后的价量、资金流、`metric`。
- **注意**：不要把「未来才确定的宏观路径」误当成 TFT 的「已知未来输入」；初学者可先不用未来已知通道，只用静态+历史序列，避免泄露争议。

(4) Transformer 类：为什么金融里要更谨慎？

- **优点**：自注意力能看「任意远」的滞后依赖。
- **风险**：参数多、数据噪声大，更容易过拟合；需要 dropout、较短窗口、或正则。

你们实验里：若上 Transformer，务必报告与 LSTM 的验证集 IC 对比，并展示训练/验证损失曲线是否验证集早早变差 (过拟合信号)。

(5) 模态 B (表格深度网络): 为什么「当天基本面」单独一路?

- **直觉**: PE、PB、市值等是**慢变量**, 主要刻画估值与规模风险; 与「过去 20 天 K 线」信息重叠又不完全等价。单独一路网络等于让模型**显式分配容量**去学估值维度。

你们实验里: `metric` 行与 `trade_date` 对齐后, 做与价量相同的截面标准化, 输入 **TabTransformer / 浅层 MLP**; 输出 s^B 。

(6) 模态 C (新闻): BERT 在你们的任务里扮演什么?

- **文献常见套路** (如 arXiv:1906.09024 等方向): 文本 $\rightarrow$ 向量 (BERT/FinBERT) $\rightarrow$ 与数值序列融合 (拼接、门控、或后接 LSTM)。
- **初学者要理解的关键**: 新闻不是「每天每只股票一条」, 必须先 **链指** 到 `ts_code` 或行业, 再做池化。

你们实验里:

1. 对每条新闻编码成向量; 按 (`ts_code`, `trade_date`) 聚合 (attention 平均或最大池化)。
2. 无新闻的股票: `mask=0`, 在融合时让门控把文本支路关掉 (不要填零向量冒充「中性新闻」)。

(7) 模态 D (指数) 与「门控»: 像空调自动模式

- **直觉**: 高波动期与低波动期, 价量因子的有效方向可能不同; 用指数波动作为**门控输入**, 让网络自己学「什么时候更信价量、什么时候更信文本」。这是业界 **regime switching** 的简化深度学习版。

你们实验里: 从 `market/000300.SH` 等计算滚动波动率, 拼到融合 MLP 的输入即可; 先在消融实验里证明「加了门控是否提升验证 ICIR」。

(8) 联合打分 (集成): 对应 Mekelburg & Strauss (2024) 与业界「多 alpha 合成」

- **秩融合**: 把各模态输出的分数先在当日截面转 rank, 再加权。好处: **每个模态尺度不同也不影响**。
- **学习权重**: 用一个小网络或 logistic 回归把 z^A, z^B, z^C 合成; 权重应在**验证期**估计, 勿在全历史上 fit。

你们实验里: 至少做三张表: 只用 A / 只用 B / A+B(+C) 的 IC、ICIR、验证回测夏普; 这是多模态作业的「硬证据」。

(9) 第六节「交作业级」最小路径 (时间不够时)

1. 仅模态 A: LSTM + 第五节特征 $\rightarrow$ IC + 回测。
2. 加模态 B: 拼接 `metric` 进 MLP 分支或与 LSTM 最后隐状态拼接。
3. 新闻与时间允许再加模态 C; 否则在报告说明「工程原因未上生产, 但已完成链指原型」也可被接受, **前提是诚实 + 第五节无泄露**。

七、交易策略设计 (对齐作业 + 实务增强)

7.1 基线策略 (作业推荐)

- 参数 n, k 网格搜索 (在验证段): 以 **ICIR、夏普、换手惩罚** 联合选参。
- **涨停/跌停过滤**: 买入侧避开当日难以成交的涨停价附近; 卖出侧对跌停流动性风险做规则约束。

7.2 扩展（仍保持可解释）

- **得分加权仓位**：在 top 组内按 $\text{softmax}(\text{score})$ 分配权重，而非严格等权。
- **风险约束**：行业最大暴露、单票最大权重、与沪深 300 的跟踪误差上限（需优化器，复杂度高于基线）。
- **与 T+1 一致**：每日可卖集合 = 昨日收盘持仓 $\cap$ 今日可卖；买入后锁仓至 +1 日。

7.3 与「满仓」约束

- 比赛要求尽可能满仓：策略层应显式把**现金比例**压到阈值以下，剩余买入预测分数次优股票直至资金用尽。

7.4 初学者导读：业界「从预测分数到持仓」怎么做，以及你们怎么对齐大作业 PDF

（1）量化股票策略的常见「翻译层」：预测 $\neq$ 组合

- **预测模型**输出的是每只股票的 **alpha 分数**（相对排序或预期超额收益）。
- ****组合构建**（portfolio construction）******才决定：买多少只、各买多少权重、多久换一次、遇到涨停/停牌怎么办。
- **业界经验**：很多团队 **IC 不错但 PnL 一般**，问题常出在翻译层（换手过高、冲击成本、约束没写）。

你们实验里：代码结构上建议分成三个函

```
数： model.predict(features) -> score ; strategy.rebalance(score, holdings, cash) -> orders ;  
backtest.simulate(orders) -> pnl 。
```

（2）作业 PDF 的 Top-Bottom k ：一种极简「排序交易」规则

- **规则复述**：持有 n 只股票等权；每天卖掉分数最低的 k 只，买入全市场分数最高的 k 只（可与自己持仓重叠处理，实现时写清楚）。
- **经济直觉**：相信模型在**横截面上**能分辨相对强弱；组合保持分散以控 idiosyncratic risk。
- **与业界关系**：类似「**多空对冲的多头侧简化版**」或「高换手单多头 rotation」；完整对冲基金还会做空头与对冲 beta，你们作业不需要。

你们实验里：

1. 先固定 $n=10, k=1$ 跑通；再在**验证集**上网格 n, k （不要拿比赛周调参）。
2. 记录每日换手、平均持有期，解释是否满足 PDF「调仓频率不应过高」。
3. 实现 **T+1**：当日买入的仓位 `sellable_mask` 次日才为真，否则回测会「幽灵收益」。

（3）涨停/跌停、流动性：业界「可成交性过滤」

- **直觉**：模型说买某只，但若一字涨停，你挂限价也未必成交；回测若假设总能按收盘价成交，会高估收益。
- **业界做法**：对不可买/不可卖状态做 **mask**；或用更保守的成交价假设（滑点）。

你们实验里：若不做逐笔撮合，至少在买入规则里加：`pct_chg < 9.5%`（主板近似）等过滤，并在报告写明这是**简化假设**。

(4) 得分加权仓位：从「等权 Top-n」到「softmax 权重」

- **文献/业界**：均值-方差框架下，最优权重常与预期收益近似线性，但需协方差矩阵估计（入门难度大）。** $\text{softmax}(\text{score})^{**}$ 是轻量启发式：分数高的权重大，但仍分散。

你们实验里：作为扩展实验，对比「等权 Top-n」与「softmax 权重」在验证夏普与最大回撤上的差异即可。

(5) 风险约束（行业上限、单票上限）：Barra 风险模型文化的「极简版」

- **业界**：用因子协方差矩阵控制组合对行业、规模、风格的暴露；你们可以用**硬约束**：单行业不超过 30%、单票不超过 10%。

你们实验里：在 rebalance 里加循环：若超配则把多余权重分配给次高分股票（与「满仓」逻辑一致）。

(6) 满仓约束：比赛规则与业界「现金管理」不同

- **比赛**：要求尽可能满仓 → 现金视为「浪费机会」但会简化评测。
- **业界**：常留部分现金应对赎回与保证金；这与作业不同，报告里一句话说明即可。

你们实验里：每日结束后若仍有现金，按分数从高到低继续买入直到买满或无可买标的，并在日志里记录「为何仍有现金」（例如全部涨停）。

(7) 第七节自查：写报告时建议附两张图

1. 预测分数分位数随时间是否漂移（模型老化）。
2. 组合行业权重随时间热力图（是否中性化失效）。

八、历史回测与评估体系

8.1 预测质量

- **IC**：每日截面相关系数序列的均值。
- **ICIR**： $\text{mean}(\text{IC})/\text{std}(\text{IC})$ ，衡量稳定性；高频 alpha 更看重 ICIR 而非单次高 IC。
- **方向胜率**（可选）：预测符号与实际符号一致的比例。

8.2 组合绩效

- **年化收益率、年化波动率、夏普比率、最大回撤**。
- **与基准对比**：沪深 300、上证综指、创业板指（数据已提供）。
- **成本敏感性**：双边千一至千三佣金 + 印花税（卖出）+ 5bps 滑点，检验是否「纸面 alpha」。

8.3 回测实施要点

- **前视偏差审计**：特征、scaler、行业映射、指数成分均用 point-in-time 版本；新闻时间戳严格对齐。
- **幸存者偏差**：本数据集为当前上市列表历史，严格而言存在幸存者偏差；报告应**诚实讨论**（学术界常用 CRSP 风格完整库缓解，课程数据受限时需在结论中声明）。

8.4 文献与业界方法对照

- **Gu, Kelly & Xiu (2020), *Review of Financial Studies***: 比较线性模型、树、神经网络等对大截面特征集的定价能力, 发现**树与神经网络**占优, 且重要信号与**动量、波动、流动性**相关。链接示例:
<https://academic.oup.com/rfs/article/33/5/2223/5758276>
- **TFT** (Lim et al., 2021, *International Journal of Forecasting*): 多输入类型与可解释注意力; 适合作为「时间序列模块」引用。
<https://arxiv.org/abs/1912.09363>
- **101 Alphas** (Kakushadze, 2016): 因子工程算子思想。
<https://arxiv.org/abs/1601.00991>
- **多模态/文本+价格**: 可参考系统性综述类工作 (如 arXiv:2212.12717 等对深度学习股价预测方法的分类综述; 以及「Learning Across Modalities」类金融多模态综述, 具体条目以 arXiv / SSRN 检索为准)。

8.5 初学者导读: IC、夏普、回撤在文献/业界里怎么用, 以及你们实验「该算哪些、怎么解读」

(1) IC: 为什么量化团队天天看「相关系数」?

- **定义直觉**: 每个交易日, 把模型预测的分数与**未来一期 (或 n 期) 收益**在几千只股票上做相关 (常用 Spearman 秩相关)。再对时间求平均得到 **mean IC**。
- **文献位置**: GKX 及大量实证资产定价论文用类似指标衡量「**横截面定价信息**»; 它不要求你预测准绝对涨幅, 只求**排序对**。
- **与深度学习损失的关系**: MSE 低不代表 IC 高; 若你们发现「训练 loss 降了但 IC 不涨», 很常见, 因为**噪声主导绝对误差**。

你们实验里: 每天算一个 IC, 画 **IC 时间序列折线图**; 报告里同时给 **mean IC** 与 **ICIR** (均值/标准差)。ICIR 低表示「信号时有时无」, 助教通常更信 ICIR。

(2) ICIR: 「平均相关」不够, 还要看「稳不稳」

- **直觉**: 某策略一年里只有两个月 IC 极高、其余月份接近 0, mean IC 可能还行, 但实盘很难依赖。ICIR 惩罚这种「不稳定」。
- **业界用法**: 高频 alpha 与多因子组合常同时报 IC 与 ICIR。

你们实验里: 对比「中性化前后」「加新闻前后」两条 IC 序列, 用 ICIR 总结哪条更稳。

(3) 年化收益与夏普: 组合层的「成绩」, 但不等于预测层成绩

- **夏普比率 (粗直觉)**: 每承担一单位波动, 平均多赚多少超额收益; 分子常用「组合收益 - 无风险利率」, 课程作业里无风险利率常近似为 0 或短债。
- **文献提醒**: 单一策略样本内夏普极高, 要怀疑泄露或过拟合; Harvey 等关于「多重检验下阈值应更严」的讨论在业界很有名 (初学者记住结论即可: **不要拿单一夏普吹嘘**)。

你们实验里:

1. 回测输出: **年化收益、年化波动、夏普、最大回撤**; 与 **沪深 300** (`market/000300.SH`) buy-and-hold 对齐同一时间轴对比。

2. 做 **成本敏感性**：佣金+印花税+5bps 滑点各跑一遍，夏普是否崩塌——崩塌说明 alpha 很薄，这是诚实结论，报告里反而加分。

(4) 最大回撤：「最坏路径」比「平均好坏」更决定你能不能拿住策略

- **直觉**：从历史峰值到谷底的最大跌幅；杠杆越高越怕回撤。
- **业界**：很多产品合同与风控直接约束最大回撤。

你们实验里：在验证集回测曲线标注最大回撤区间（起止日期），并讨论是否发生在某一市场阶段（如 2015、2020 疫情等），与 Rossi (2021)「结构突变」叙事呼应。

(5) 基准对比：不是形式主义，而是回答「我有没有赚到 beta」

- **直觉**：牛市里随便买股票也可能涨；你要证明模型相对 **市场宽基** 有 **超额 (alpha)**。
- **数据**：你们已有上证、沪深 300、创业板指日行情。

你们实验里：至少画两条净值曲线：**你的策略 vs 等权持有沪深 300**（或买入持有指数）；并报告 **信息比率 (IR)** 近似：超额收益均值/超额收益波动（若课程未要求可省略公式，用文字描述）。

(6) 前视偏差与「回测引擎」：业界与学术的共识

- **前视偏差例子**：用「全样本」算的行业分类回测过去；用未来才公布的指数成分选股；新闻时间晚于收盘却记入当日特征。
- **业界**：回测系统强调 **point-in-time (PIT) 数据库**；你们用 CSV 也要模仿这一精神。

你们实验里：写一页「**数据泄露审计清单**」：逐条对照第五节 5.11 表，并在附录给 1-2 个「故意做错版本」的对照（例如全样本 scaler）展示 IC 如何虚高——这是极强的教学展示（注意：对照实验勿与正式结果混淆）。

(7) 幸存者偏差：你们数据能说什么、不能说什么

- **直觉**：若股票池只含「现在还活着的公司」，过去表现会被系统性抬高。
- **学术**：严格研究需要包含退市股票；课程数据若做不到，要在报告 limitation 里写清楚。

你们实验里：结论里避免「我发现了 A 股永恒规律」式表述；改成「在提供的数据与股票池定义下，样本内/验证期表现……」。

(8) 第八节「交作业级」输出清单（建议直接当报告目录小节）

1. 训练/验证 loss 曲线 + 早停说明。
2. IC / ICIR 表 + IC 时间序列图。
3. 回测：净值、年化、夏普、最大回撤 + 与沪深 300 对比。
4. 成本敏感性表。
5. 数据泄露与幸存者偏差讨论各一段。

九、业界实践归纳：为何这些方法有效

环节	常见做法	背后原理
标签	超额收益、多 horizon	去除共同因子暴露后，预测 异质性风险调整收益 更稳定
截面处理	rank、z-score、行业中性	降低分布漂移与非平稳性；与排序选股目标（IC）一致
模型	树集成 + 神经网络	高维交互与非平滑结构；正则化与早停防过拟合
文本	预训练语言模型 + 聚合	非结构化信息中的 事件冲击 与情绪扩散
评估	IC/IR + 成本后回测	相关性与 PnL 不完全等价；成本检验可部署性
部署	滚动重训、监控漂移	概念漂移在制度与市场结构变化下不可避免

十、全数据使用的落地检查清单（建议写入正式实验报告）

- 1. 价量：daily 全历史 + 指数 market 对齐。
- 2. 基本面/资金流：metric、moneyflow 与 daily 按 ts_code, trade_date 内连接。
- 3. 新闻：news 全量跑 NLP 管线；**2019 前**用 mask/仅子模型。
- 4. 过滤：stock_st 剔除 ST；basic.market 或 ts_code 剔除北交所。
- 5. 无泄露 scaler 与标签 shift。
- 6. 联合模型在验证集上报告 **各模态消融**（A/B/C 单独与融合）。

十一、参考文献与链接（便于在终稿中按 BibTeX 规范化）

1. Shihao Gu, Bryan Kelly, Dacheng Xiu. *Empirical Asset Pricing via Machine Learning*. **The Review of Financial Studies**, 2020.
<https://academic.oup.com/rfs/article/33/5/2223/5758276>

2. Stefano Giglio, Yuan Liao, Dacheng Xiu. *Thousands of Alpha Tests*. **The Review of Financial Studies**, 2021.
https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3259268

3. Guanhao Feng, Stefano Giglio, Dacheng Xiu. *Taming the Factor Zoo: A Test of New Factors*. **The Journal of Finance**, 2020.
<https://doi.org/10.1111/jofi.12927>

4. Serhiy Kozak, Stefan Nagel, Shrihari Santosh. *Shrinking the Cross-Section*. **Journal of Financial Economics**, 2020.
<https://doi.org/10.1016/j.jfineco.2019.07.008>

5. Erik Mekelburg, Jack Strauss. *Pooling and winsorizing machine learning forecasts to predict stock returns with high-dimensional data*. **Journal of Empirical Finance**, 2024, DOI: 10.1016/j.jempfin.2024.101538.
<https://ideas.repec.org/a/eee/empfin/v79y2024ics0927539824000732.html>

6. Marcos López de Prado. *Advances in Financial Machine Learning*. Wiley, 2018. (Purged CV / embargo 等验证框架)
7. Zura Kakushadze. *101 Formulaic Alphas*. arXiv:1601.00991, 2016.
<https://arxiv.org/abs/1601.00991>
8. Bryan Lim et al. *Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting*. *International Journal of Forecasting*, 2021 (preprint arXiv:1912.09363).
<https://arxiv.org/abs/1912.09363>
9. 金融情感与深度学习结合方向 (示例预印本, 终稿请核对卷期页):
 - arXiv:1906.09024; arXiv:2403.04427; arXiv:2407.16150 等。
10. 深度学习股价预测综述类 (示例): arXiv:2212.12717 (请在引用前核对题名与版本)。
11. Tidy Finance 博客: GKX 复现中对截面秩变换至 $[-1,1]$ 的实现说明:
<https://www.tidy-finance.org/blog/gu-kelly-xiu-replication/>
12. Barbara Rossi. *Forecasting in the Presence of Instabilities*. *Journal of Economic Literature*, 2021 (预测模型在结构变化下的评估与改进综述, 可与 walk-forward 设计对照阅读)。

十二、小结

本作业在统计上是一个**大截面、短面板、强噪声**的排序预测问题; 在工程上是一个**严格因果对齐**的数据管道问题。建议流程上**先完成第五节(预处理与特征工程)**: 时间 walk-forward、purged/embargo 验证思想、逐期截面秩或 winsorize、行业与规模中性、量纲统一与防泄露标准化; 再进入**第六节**多模态深度模型与联合打分; 策略上实现 PDF 的 **Top-Bottom k 换手** 并满足 $T+1$ 与满仓约束; 评估上 **IC/IR 与成本后夏普、最大回撤** 并重, 并与沪深 300 等基准对照。文献与业界上, 该路线对齐 GKX (2020) 的大截面机器学习资产定价实践、Giglio-Liao-Xiu (2021) 与 Feng-Giglio-Xiu (2020) 对数据窥探与因子冗余的警示、Kozak-Nagel-Santosh (2020) 的收缩思想、Mekelburg-Strauss (2024) 对预测集成与 winsorize 的实证支持, 以及 101 Alphas 与 FinBERT 类工作的工程文化。

报告撰写说明: PDF 内容已通过本地读取核对; data 具体字段以 data/README.md 为准; 新闻与多股关联需在实现阶段补充算法细节与消融实验表格。